

Automatyczna analiza melodyczno-rytmiczna playlisty MIDI w kontekście rytmicznej stymulacji słuchowej

Krzysztof Czuba
Piotr Skowroński

Praca pokazuje, jak z plików MIDI automatycznie wyznaczyć cechy melodyczno-rytmiczne i wykorzystać je do oceny muzyki jako bodźca rytmicznego. Analizujemy 15 utworów, wstępnie podzielonych na trzy grupy: RAS (chód), relaksacja i muzyka złożona. Dla każdego utworu mierzymy tempo, regularność onsetów, wyrazistość pulsu, synkopację i złożoność formy. Cech tych używamy dwójako: do grupowania utworów (sprawdzamy, czy obiektywne parametry odtwarzają nasz wstępny podział) oraz do wskaźnika przydatności utworu jako bodźca *Rhythmic Auditory Stimulation* (RAS). Otrzymujemy trzy wnioski. Tempo jest warunkiem koniecznym, ale niewystarczającym. Wyrazistość pulsu jest wiązana ze zdolnością do synchronizacji ruchu. „Złożoność”, zaś rozpada się na dwie osobne osie: rytmiczną i formalną. Pracę traktujemy jako prototyp metody i jawnie nazywamy jej ograniczenia: uproszczenia zapisu MIDI i małą próbę.

17 czerwca 2026

Spis treści

1. Wprowadzenie i cel	3
2. Tło teoretyczne	4
3. Dane i metoda	5
3.1. Dlaczego MIDI?	5
3.2. Korpus	5
3.3. Pipeline ekstrakcji	5
3.4. Cechy rytmiczno-formalne	5
3.5. Wskaźnik przydatności do RAS	6
3.6. Klasteryzacja i uwaga metodologiczna	6
4. Wyniki	7
4.1. Profile cech grup apriorycznych	7
4.2. Klasteryzacja: „złożoność” jest dwuwymiarowa	8
4.3. Przydatność do Rhythmic Auditory Stimulation	10
5. Dyskusja	11
6. Ograniczenia	12
7. Wnioski i kierunki dalsze	13
Załącznik: kluczowe funkcje modułu melody.py	14
Bibliografia	15

1. Wprowadzenie i cel

Muzyka może być traktowana jako uporządkowany bodziec czasowy: sekwencja zdarzeń dźwiękowych o mierzalnym tempie, rytmie, regularności i strukturze pulsu. W takim ujęciu szczególnie interesujące są zastosowania, w których parametry muzyki mogą wspierać synchronizację ruchu, regulację pobudzenia lub projektowanie powtarzalnego bodźca terapeutycznego.

Celem niniejszego opracowania jest sprawdzenie, czy z plików MIDI da się automatycznie wydobyć cechy, które mają sens interpretacyjny w kontekście **muzycznego porywania** (*music entrainment*) i **rytmicznej stymulacji słuchowej** (*Rhythmic Auditory Stimulation*, RAS): tempo, regularność onsetów, wyrazistość pulsu, synkopację oraz złożoność formalną.

Praca ma charakter prototypu metody: łączy ekstrakcję cech z symbolicznej reprezentacji MIDI, porównanie utworów w przestrzeni cech oraz prosty wskaźnik przydatności do RAS. Nie próbuje oceniać wartości artystycznej utworów ani formułować zaleceń klinicznych.

2. Tło teoretyczne

Muzyczne porywanie (entrainment). Zdolność układu nerwowo-mięśniowego do synchronizacji z zewnętrznym, periodycznym bodźcem rytmicznym jest dobrze udokumentowana. Według Thauta [1] rytm działa jak zewnętrzny zegar, do którego mimowolnie dostrajają się wzorce ruchowe; mechanizm ten leży u podstaw neurorehabilitacji ruchu.

Rytmiczna stymulacja słuchowa (RAS). W zastosowaniu klinicznym regularny bodziec słuchowy poprawia parametry chodu u pacjentów z deficytami motorycznymi. Murgia i współautorzy [2] wykazali w badaniu z randomizacją, że bodziec rytmiczny (odgłosy kroków) normalizuje chód w chorobie Parkinsona. Kluczowe dla skuteczności RAS są: **przewidywalność i wyrazistość pulsu** oraz **tempo** możliwe do sprzęgnięcia z kadencją kroków.

Programowanie muzyki terapeutycznej. Natanson [3] oraz Cylulko [4] podkreślają, że dobór muzyki terapeutycznej nie powinien być przypadkowy, lecz wynikać z celowego dopasowania parametrów bodźca do funkcji terapeutycznej. To stanowi bezpośrednie uzasadnienie dla obiektywizacji cech muzycznych, którą podejmuje niniejsza praca. Szerszy kontekst uwarunkowań odbioru muzyki omawia Pałosz [5].

Z powyższego wynika robocza teza pracy: cechy takie jak tempo, regularność onsetów, wyrazistość pulsu i synkopacja pozwalają obiektywizować potencjał utworu jako bodźca rytmicznego, niezależnie od subiektywnej oceny jego atrakcyjności.

3. Dane i metoda

3.1. Dlaczego MIDI?

MIDI (*Musical Instrument Digital Interface*) nie jest nagraniem audio, lecz symbolicznym opisem zdarzeń muzycznych: zawiera m.in. wysokości dźwięków, momenty ich rozpoczęcia, czas trwania, kanały/instrumenty oraz informacje o tempie. Dzięki temu pozwala analizować strukturę rytmiczną i melodyczną bez wcześniejszej separacji źródeł z sygnału audio.

Format MIDI wybrano, ponieważ dobrze pasuje do celu pracy: umożliwia bezpośrednio wyznaczanie onsetów, tempa, przybliżonej melodii prowadzącej i cech formalnych w sposób powtarzalny dla wielu utworów. Jest to korzystne przy prototypowaniu metody porównawczej, w której ważniejsza jest spójność reprezentacji niż wierność pojedynczemu wykonaniu.

Konsekwencją tego wyboru jest ograniczenie interpretacji wyników. MIDI upraszcza brzmienie, dynamikę i ekspresję wykonawczą, a wiele plików ma sztywne tempo. Dlatego uzyskane cechy opisują przede wszystkim zapis symboliczny utworu, nie pełne doświadczenie akustyczne konkretnego nagrania.

3.2. Korpus

Analizie poddano 15 plików MIDI dobranych tak, by reprezentowały trzy **grupy aprioryczne** o domniemanej różnej funkcji:

- **RAS** - utwory o regularnym pulsie i marszowym lub tanecznym charakterze (Sousa, Strauss, Elgar, Survivor, Bee Gees);
- **relaksacja** - utwory wolniejsze, o niższej gęstości zdarzeń (Satie, Debussy, Pachelbel, Beethoven, Chopin);
- **złożoność** - utwory o nietypowym metrum lub zmiennej strukturze (Queen, Brubeck, Pink Floyd, King Crimson, Radiohead).

Podział ten traktujemy jako **hipotezę do sprawdzenia**: czy obiektywne cechy odtworzą ten intuicyjny podział funkcjonalny?

Warto zauważyć asymetrię w samych definicjach grup: „RAS„ i „relaksacja” określono **funkcjonalnie** (przez zamierzony efekt bodźca), a „złożoność„ **strukturalnie** (przez budowę utworu). Asymetria jest celowa - pozwala sprawdzić, czy strukturalna złożoność przekłada się na odrębne, mierzalne cechy. Jak pokażą wyniki, przekłada się tylko częściowo, bo sama „złożoność” rozpada się na osobne osie rytmiczną i formalną.

3.3. Pipeline ekstrakcji

Dla każdego pliku: (1) detekcja głównego głosu melodycznego z ciągłością w czasie (`track_lead_voice`), (2) wyrównanie okien analizy do siatki beatów wyznaczonej z mapy tempa MIDI, (3) wyznaczenie cech melodycznych i rytmiczno-formalnych. Kod analityczny zebrano w module `melody.py`, a eksperyment w notatniku `4_comparison.ipynb`.

3.4. Cechy rytmiczno-formalne

Do opisu bodźca pod kątem RAS wybrano cechy o jasnej interpretacji fizycznej:

- **Tempo złożone do pasma kadencji** (`fold_bpm_to_band`). MIDI zapisuje tempo na poziomie ćwierćnuty, więc utwory w metrum *alla breve* (marsze) mają tempo zawyżone dwukrotnie (np. *Stars and Stripes* ≈ 222 zamiast ≈ 111 BPM). Składamy więc tempo o metryczne oktawy ($\div 2$), ale **tylko w dół** - tak usuwamy ten artefakt, a zarazem nie zawyżamy utworów naprawdę wolnych. Dzięki temu wartość odpowiada realnemu tempu bodźca, w zakresie typowym dla synchronizacji ruchu.
- **Wyrazistość pulsu** (`pulse_clarity`) - wysokość najsilniejszego szczytu autokorelacji wygładzonej obwiedni onsetów w paśmie pulsu, znormalizowana do energii w zerze. Wartość bliska 1 oznacza wyraźny, regularny puls; niska - materiał rubato lub ametryczny.
- **Synkopacja** (`syncopation`) - udział onsetów przypadających na słabe części taktu, ważony hierarchią metryczną na siatce beatów; mierzy rytmiczną „nieoczywistość”.
- **Złożoność formalna** (`form_complexity`) - średnia odległość kosinusowa między oknami czasowymi w macierzy samopodobieństwa (profil chroma + gęstość + rejestr). Niska dla utworu jednorodnego (jedna sekcja), wysoka dla wielosekcyjnego lub modulującego.
- **Regularność odstępów** (`ioi_cv` , `ioi_entropy`) - współczynnik zmienności i entropia odstępów międzyonsetowych (IOI).

3.5. Wskaźnik przydatności do RAS

Trzy warunki, które literatura [1], [2] wiąże ze skuteczną synchronizacją ruchu, łączymy w jeden wskaźnik. Używamy **średniej geometrycznej**, bo wtedy słaby wynik na dowolnym z warunków obniża cały wskaźnik:

$$S = \sqrt[3]{c \cdot p \cdot (1 - s)} \quad (1)$$

gdzie c - dopasowanie kadencji (tempo złożone w paśmie $\approx 90\text{--}130$ kroków/min, z liniowym spadkiem poza pasmem), p - wyrazistość pulsu, a $(1 - s)$ - przewidywalność (im mniej synkopacji, tym wyższa). Wskaźnik mierzy to, jak łatwo zsynchronizować ruch z pulsem - nie energię ani pobudzenie.

3.6. Klasteryzacja i uwaga metodologiczna


Cechy standaryzujemy (`StandardScaler`) i grupujemy metodą Warda na trzy klastry. Używamy przy tym **tylko cech rytmiczno-formalnych**. Świadomie pomijamy 12-elementowy histogram klas wysokości (koduje on tonację): po standaryzacji zdominowałyby odległości i utwory grupowałyby się według tonacji, a nie funkcji.

Ważny wybór: cechy dobraliśmy z góry, na podstawie teorii, a **nie** tak, by klastry jak najlepiej pasowały do etykiet. Gdybyśmy dostrajali je pod tę jedną 15-utworową próbę, łatwo byłoby zobaczyć wzór, którego naprawdę nie ma. Dlatego przy tak małej próbie traktujemy wynik jako prototyp metody, a nie potwierdzony rezultat.

4. Wyniki

4.1. Profile cech grup apriorycznych

Rysunek 1 przedstawia uśrednione, znormalizowane profile cech dla trzech grup. Grupy różnią się przede wszystkim na osiach pulsu, gęstości onsetów i tempa, lecz profile częściowo się przenikają - pierwszy sygnał, że podział aprioryczny nie jest jednowymiarowy.



Rysunek 1: Uśrednione profile cech (min-maks) dla grup apriorycznych.

Tabela 1 zestawia kluczowe cechy oraz wskaźnik przydatności do RAS dla całego korpusu (uszeregowany malejąco wg przydatności).

Utwór	KAT.	BPM	PULS	SYNK.	FORMA	PRZYD.	OCENA RAS
Gymnopédie No. 1	relaks.	90	0.75	0.01	0.19	0.906	dobry
Stars and Stripes	RAS	111	0.68	0.22	0.10	0.811	dobry
Bohemian Rhapsody	złoż.	103	0.66	0.33	0.25	0.764	dobry
Radetzky March	RAS	95	0.47	0.12	0.11	0.745	dobry
Pomp and Circumstance	RAS	90	0.56	0.29	0.19	0.734	dobry
Eye of the Tiger	RAS	119	0.59	0.37	0.14	0.720	dobry
Canon in D	relaks.	77	0.87	0.27	0.15	0.712	dobry
Stayin' Alive	RAS	104	0.54	0.43	0.09	0.677	warunkowy
Money	złoż.	126	0.39	0.29	0.12	0.652	warunkowy
21st Century Schizoid Man	złoż.	124	0.43	0.41	0.18	0.635	warunkowy
Clair de Lune	relaks.	83	0.52	0.45	0.24	0.606	warunkowy
Paranoid Android	złoż.	77	0.53	0.35	0.20	0.577	warunkowy
Take Five	złoż.	84	0.34	0.30	0.14	0.574	warunkowy

UTWÓR	KAT.	BPM	PULS	SYNK.	FORMA	PRZYD.	OCENA RAS
Moonlight Sonata I	relaks.	45	0.89	0.44	0.18	0.291	nieodpowiedni
Nocturne Op. 9 No. 2	relaks.	58	0.41	0.40	0.21	0.230	nieodpowiedni

Tabela 1: Cechy rytmiczno-formalne i wskaźnik przydatności do RAS. BPM - tempo złożone do pasma kadencji; Puls - pulse_clarity; Synk. - synkopacja; Forma - form_complexity; Przyd. - wskaźnik *S*.

4.2. Klasteryzacja: „złożoność” jest dwuwymiarowa


Klastrowanie na siedmiu cechach rytmiczno-formalnych **nie odtwarza** trzech kategorii apriorycznych (Tabela 2): każda kategoria rozkłada się na różne klastry. Struktura nie jest jednak losowa - grupa „złożona”, koncentruje się (4 z 5 utworów w jednym klastrze) i **nie pojawia się** w klastrze materiału o najwyższej regularności pulsu, ku któremu ciąży relaksacja.

KATEGORIA APRIORYCZNA	KLASTER 0	KLASTER 1	KLASTER 2
RAS	2	2	1
relaksacja	2	3	0
złożoność	4	0	1


Tabela 2: Tabela zgodności: kategorie aprioryczne wobec klastrów algorytmu.

Najważniejszy wynik ujawnia cecha form_complexity. Okazuje się, że *Take Five* (forma 0.14) i *Money* (0.12) mają **niską** złożoność formalną - są to powtarzalne groove’y (ostinato w 5/4, riff w 7/4), złożone **rytmicznie** (niski pulse_clarity), ale formalnie jednorodne. Wysoką złożoność formalną mają faktycznie wielosekcyjne *Bohemian Rhapsody* (0.25) i *Paranoid Android* (0.20). Co więcej, romantyczne utwory „relaksacyjne”, - *Clair de Lune* (0.24), *Nocturne* (0.21) - także wypadają wysoko, bo modulują i zmieniają fakturę. Wniosek: aprioryczna etykieta „złożona” **miesza dwa różne zjawiska** - złożoność rytmiczną i formalną. Cecha policzona z przesłanek teoretycznych, a nie dostrojona pod etykiety, ujawniła strukturę, której nie zakładano.

Strukturę hierarchiczną i podobieństwa ilustrują Rysunek 2 oraz Rysunek 3.




Rysunek 2: Dendrogram (metoda Warda).



Rysunek 3: Podobieństwo (1 – znorm. odl. euklidesowa, cechy standaryzowane).

4.3. Przydatność do Rhythmic Auditory Stimulation

Wskaźnik S dał ranking utworów jako potencjalnych bodźców RAS (Rysunek 4; wartości w Tabela 1). Progi klas (dobry / warunkowy / nieodpowiedni) są **ilustracyjne**, nie klinicznymi punktami odcięcia.



Rysunek 4: Ranking przydatności do RAS; kolor oznacza kategorię aprioryczną. Linie pionowe - progi ilustracyjne 0,45 i 0,70.

Wskaźnik dobrze ilustruje, że przydatność do RAS jest **iloczynem** trzech niezależnych warunków - wystarczy, że jeden zawiedzie, by utwór odpadł. Cztery przypadki kontrastowe:

- **Stars and Stripes Forever** (≈ 0.81) - *idealny kandydat*. Tempo składa się do ≈ 111 BPM (środek pasma kadencji), puls wyrazisty, niska synkopacja. Marszowy charakter czyni go przykładem bardzo stabilnego bodźca rytmicznego.
- **Moonlight Sonata** (≈ 0.29) - *odpada mimo czystego pulsu*. Ma najwyższą w korpusie wyrazistość pulsu (0.89), lecz tempo 45 BPM leży daleko poniżej przyjętego pasma kadencji. Tempo spoza pasma drastycznie obniża wskaźnik (choć go nie zeruje) - **tempo pozostaje twardym ograniczeniem**.
- **Take Five** (≈ 0.57) - *tempo dobre, puls za słaby*. Tempo (84 BPM) mieści się w paśmie, ale metrum 5/4 daje niski `pulse_clarity` (0.34) - regularna synchronizacja z takim pulsem jest trudniejsza. Pokazuje, że **sama kadencja nie wystarcza**.
- **Gymnopedie No. 1** (≈ 0.91 , najwyżej) - *przypadek pouczający*. To utwór „relaksacyjny”, a wypada najlepiej, bo ma regularny puls w paśmie kadencji i niemal zerową synkopację. Wskaźnik mierzy **entrainowalność pulsu**, a nie pobudzenie - spokojny, miarowy utwór bywa świetnym metronomem.

5. Dyskusja

Tempo jest warunkiem koniecznym, ale niewystarczającym. Po złożeniu tempa większość playlisty trafia w zakres $\approx 77\text{--}126$ BPM - obszar potencjalnie użyteczny dla synchronizacji ruchu. Samo tempo nie rozdziela jednak funkcji bodźca: muzyka marszowa, taneczna i spora część materiału „relaksacyjnego”, mają podobny puls.

Wyrazistość pulsu a synchronizacja ruchu. Wyrazistość pulsu zachowuje się zgodnie z teorią: jest najwyższa dla utworów o stabilnym, prostym pulsie (*Moonlight* 0.89, *Canon* 0.87), a najniższa dla metrum nieparzystego i zmiennej faktury (*Take Five* 0.34). To właśnie ta cecha - według Thauta [1] - decyduje o tym, czy ruch da się zsynchronizować z muzyką.

Złożoność ma dwie twarze. Nasz najważniejszy wniosek: złożoność rytmiczna (nieparzyste metrum, słaby puls) i złożoność formalna (wiele sekcji, modulacje) to **dwie osobne rzeczy**, a wstępna etykieta „złożona”, je myli. Dobrze pokazuje to, po co dobieraliśmy cechy z góry, a nie pod etykiety: cecha, której nie naginaliśmy do podziału, ujawniła w danych strukturę, której się nie spodziewaliśmy.

Mierzalny opis bodźca. W duchu Natansona [3] i Cylulki [4] praca pokazuje, że świadomy dobór muzyki terapeutycznej wymaga kilku uzupełniających się, mierzalnych cech. Dopiero wyrazistość pulsu, synkopacja i złożoność formy dodały do opisu osobne osie: przewidywalność pulsu oraz złożoność rytmiczną i formalną. Klastrowanie służy tu do sprawdzenia podziału, a nie do potwierdzania go z góry.

6. Ograniczenia

- **Reprezentacja symboliczna.** MIDI nie zawiera sygnału audio ani mikro-timingu żywego wykonania. Wyniki dotyczą więc struktury zapisanej w MIDI, nie konkretnego nagrania audio. Analiza brzmienia, mikro-timingu i cech widmowych wymagałaby renderu MIDI do audio albo pracy bezpośrednio na nagraniach.
- **Mała próba.** $N = 15$ w przestrzeni 7-wymiarowej oznacza, że struktura klastrów jest niestabilna; wynik to prototyp, nie dowód.
- **Heurystyka melodii.** Detekcja głównego głosu opiera się na najwyższym aktywnym dźwięku - uproszczenie zawodzące w gęstej fakturze.
- **Subiektywne etykiety.** Podział aprioryczny jest intuicyjny i - jak pokazano - niejednorodny (miesza funkcję bodźca ze strukturą utworu); to hipoteza do sprawdzenia, a nie „prawda”, referencyjna.
- **Brak walidacji na ludziach.** Wskaźnik przydatności do RAS opiera się na przesłankach teoretycznych, nie na pomiarze reakcji ruchowej lub fizjologicznej.

7. Wnioski i kierunki dalsze

Zbudowano kompletny pipeline obiektywizacji bodźca muzycznego: od ekstrakcji cech rytmiczno-formalnych, przez klastrowanie testujące podział aprioryczny, po wskaźnik przydatności do RAS z interpretowalnym uzasadnieniem. Najważniejsze wnioski: tempo jest konieczne, lecz niewystarczające; wyrazistość pulsu to korelat wiązany w literaturze z entrainmentem; pojęcie złożoności jest dwuwymiarowe.

Kierunki dalsze, uszeregowane wg stosunku wartości do nakładu:

1. **Tania walidacja** - wskaźnik zgodności klastrow z etykietami (ARI) oraz analiza stabilności (leave-one-out / bootstrap), by zamienić deklarowaną niestabilność na zmierzoną.
2. **Render do audio + analiza widmowa** (FFT, reprezentacje melowe) - jedyna droga, by rzetelnie objąć cechy widmowe i mikro-timing.
3. **Powiększenie korpusu** i ewentualne sprzężenie cech z biofeedbackiem (np. parametry ruchu, tętno, HRV, reakcja elektrodermalna) - krok ku rzeczywistemu systemowi wspomagania terapii.

Załącznik: kluczowe funkcje modułu `melody.py`

FUNKCJA	ROLA
<code>track_lead_voice</code>	Śledzenie głównego głosu melodycznego z ciągłością w czasie.
<code>fold_bpm_to_band</code>	Składanie tempa metrycznymi oktavami do pasma kadencji.
<code>compute_pulse_clarity</code>	Wyrazistość pulsu z autokorelacji obwiedni onsetów.
<code>compute_syncopation</code>	Udział onsetów na słabych częściach taktu (hierarchia metryczna).
<code>compute_form_complexity</code>	Złożoność formalna z macierzy samopodobieństwa okien.
<code>compute_ioi_features</code>	Regularność odstępów międzyonsetowych (<code>ioi_cv</code> , <code>ioi_entropy</code>).
<code>compute_entrainment_suitability</code>	Złożony wskaźnik przydatności do RAS (średnia geometryczna).
<code>compute_feature_vector</code>	Agregacja wszystkich cech utworu do wspólnego słownika.

Bibliografia

- [1] M. H. Thaut, „Biomedical Research in Music”, w *Rhythm, Music, and the Brain: Scientific Foundations and Clinical Applications*, Routledge, 2013, s. 61–84.
- [2] M. Murgia *et al.*, „The Use of Footstep Sounds as Rhythmic Auditory Stimulation for Gait Rehabilitation in Parkinson's Disease: A Randomized Controlled Trial”, *Frontiers in Neurology*, t. 9, 2018.
- [3] T. Natanson, *Programowanie muzyki terapeutycznej*. 1992.
- [4] P. Cylulko, „Diagnoza i diagnostyka muzykoterapeutyczna”, w *Programowanie muzyki terapeutycznej*, P. Cylulko i J. Gładyszewska-Cylulko, Red., 1992.
- [5] P. Pałosz, „Przegląd badań nad uwarunkowaniami preferencji muzycznych”, *Przegląd Psychologiczny*, t. 52, nr 2, 2009.